

Room Type Classification

Классификация изображений помещений на 20 классов

Финальная защита | 8 минут pitch + 7 минут Q&A

Computer Vision • PyTorch • ConvNeXt • MLflow

0.7934

лучшая модель-кандидат
final OOF macro F1

20

классов
схема 0..19

Top-K

формат ответа
class + probability

Команда: **Давид Сухашвили, Алексей Тепляков, Лина Цаплева, Дарья Вдовина, Михаил Калмыков, Глеб Медведев**

Репозиторий: https://github.com/Bersserker/hakathon_room_cv

1. Бизнес-контекст и задача

Что заказчик получает от автоматической классификации помещений

Боль сейчас

Ручная проверка и разметка объявлений занимает время;

Ошибки в типах комнат ухудшают фильтры и поиск;

Визуально близкие классы путаются даже человеком;

Дисбаланс классов усложняет стабильную автоматизацию.

ML-решение

На входе - фотография помещения или объекта;

Модель возвращает ID класса, название и вероятности;

Топ-K помогает использовать модель как подсказку для модерации;

Pipeline воспроизводим: данные, обучение, инференс, артефакты.

Бизнес-эффект

Ускорение обработки объявлений;


Более точные фильтры и рекомендации;

Рост качества данных для аналитики и модерации;

Основа для полуавтоматической проверки карточек.

2. Как решение работает в продукте

От фотографии объявления до результата для модерации, поиска и аналитики



Выход модели { `class_id`, `class_name`, `probability`, `top_k` }

Режим внедрения: сначала decision support, затем автоматизация для уверенных предсказаний.

3. Данные и сложности классификации

Почему macro F1 выбран как главная метрика

20

Классов в схеме
0..19

image

Основной input
фото помещения

macro F1

Главная метрика
устойчива к дисбалансу

Top-K

Сложные зоны
похожие классы

Основные риски данных

Дисбаланс по классам;
Разное качество и ракурсы
фотографий;
Похожие визуальные признаки
между комнатами;
Классы “не ясно” и “комната без
мебели”.

Что сделали


Manifest и аудит файлов;
Фиксированные split-ы / folds;
Balanced sampler;
Focal Loss для сложных и редких
классов.

Почему macro F1

Accuracy может скрыть
Провалы на редких классах;
Macro F1 усредняет качество
по классам;
Лучше отражает качество для
бизнес-категорий.

4. Этапы работы и принятые решения

Путь от сырого датасета до воспроизводимого inference-пайплайна



Ключевое инженерное решение

Не делать “одноразовый notebook-only” результат: весь pipeline вынесен в скрипты, конфиги, MLflow-логирование и release config для инференса.

Что это даёт заказчику

Решение можно повторить, проверить, дообучить на новых данных и развернуть как API/demo без ручного восстановления эксперимента.

5. Финальная модель и rationale

Почему выбран тяжёлый ConvNeXt pipeline для финального решения

Финальная конфигурация

Backbone: ConvNeXt XLarge;
input size: 512×512;

Loss: Focal Loss;

Sampler: balanced sampler;

Early stopping;

AMP + gradient checkpointing.

Почему так

Большая модель лучше
извлекает визуальные детали;

512×512 сохраняет больше
признаков интерьера;

Focal Loss помогает
фокусироваться на сложных
примерах;

Balanced sampler снижает
перекас в сторону частых
классов.

Контроль качества

Валидация на folds;

OOF-предсказания;


Shadow holdout;

MLflow для параметров и
метрик;

Release config для
воспроизводимого inference.

6. Результаты экспериментов

Run #1 выбран как основной кандидат по OOF macro F1



0.7934

best_val_macro_f1
Run #1

0.7934

final_oof_macro_f1
Run #1

0.8024


best shadow accuracy
Run #5

Вывод

Run #1 лучше по целевой метрике macro F1 на OOF. Run #5 показывает лучшую accuracy на shadow, но более низкий macro F1 - это сигнал возможного смещения в сторону частых классов.

7. Анализ качества: ассигасу недостаточно

Почему финальный выбор делаем по macro F1, а не только по ассигасу



Интерпретация

На shadow holdout Run #5 даёт максимальную ассигасу, но не лучший macro F1. Для продуктовой классификации важно не только хорошо угадывать частые классы, но и сохранять качество на редких категориях.

Типовые зоны ошибок

спальня / гостиная / студия;
кухня / кухня-гостиная;
гардеробная / кладовая / постирочная;
ванная / совмещённый санузел;
неясные фото и комнаты без мебели.

8. Прототип и production-интерфейс

Модель подготовлена к демо-режиму и API-интеграции

Demo

Gradio demo для ручной проверки;

Загрузка изображения;

Визуальный просмотр предсказания;

Удобно для защиты и внутреннего QA.

API

POST /predict;

Multipart/form-data image;

Response: class_id, class_name, probability, top_k;

RoomPredictor как единая inference-обёртка.

Пример JSON ответа

```
{
  "class_id": 3,
  "class_name":
"kitchen",
  "probability": 0.87,
  "top_k": [
    {"kitchen": 0.87},
    {"living_room":
0.08},
    {"studio": 0.03}
  ]
}
```

9. Воспроизводимость и материалы проекта

Что заказчик может проверить после защиты

Блок	Где лежит	Что содержит
Код проекта	GitHub repo	github.com/Bersserker/hakathon_room_cv
Документация	docs/	ход работы, MLflow, pipeline decisions
Отчёты	reports/	метрики, аудит схемы, финальные результаты
Эксперименты	mlflow_runs.csv / mlruns	параметры, метрики, артефакты запусков
Demo	demo/app.py	локальный запуск Gradio demo
Release	configs/release/rc1.yaml	конфиг финального инференса

Главная ссылка: https://github.com/Bersserker/hakathon_room_cv

10. Внедрение и бизнес-метрики

Как перевести ML-результат в продуктовую пользу

MVP-режим

Использовать модель как подсказку модератору;

Автоматизировать только high-confidence предсказания;

Логировать top-k и feedback; собирать ошибки для дообучения.

KPI для заказчика

Сокращение времени ручной разметки;

Доля карточек с корректным типом помещения;

Снижение числа ручных исправлений;

Macro F1 по новым данным; coverage при заданном confidence threshold.

Следующие шаги

Добавить confusion matrix в регулярный отчёт;

Настроить active learning для сложных классов;

Калибровать вероятности; добавить мониторинг drift;

Провести A/B или offline impact analysis.

11. Команда, вклад и формат защиты

Один спикер, централизованная стратегия ответов на вопросы

Участник	Роль	Вклад
Давид Сухашвили	Team Lead / ML pipeline	архитектура pipeline, финальная модель, интеграция результатов, защита и Q&A
Алексей Тепляков	Data / EDA	аудит данных, manifest, анализ классов и проблем качества
Лина Цаплева	Experiments	подготовка конфигов, запуск экспериментов, фиксация параметров
Дарья Вдовина	Evaluation	метрики, OOF/shadow evaluation, интерпретация результатов
Михаил Калмыков	Inference / API	RoomPredictor, release config, API/Docker направление
Глеб Медведев	Docs / Demo	документация, demo-сценарий, презентационные материалы

Формат выступления

Один спикер: Давид. Структура pitch рассчитана на 8 минут.

Q&A

Давид отвечает за все вопросы; при необходимости ссылается на блоки: данные, модель, метрики, API, docs.

12. Итог: что готово к финальной защите

Проект закрывает бизнес-задачу и имеет воспроизводимый ML/CV pipeline

Готово сейчас

Датасет проверен через manifest и аудит;

Обучение через fold pipeline реализовано;

Эксперименты логируются в MLflow;

OOF/shadow predictions экспортируются;

Финальная модель выбрана по macro F1;
demo/API направление подготовлено.

Финальный результат

Основной кандидат: ConvNeXt XLarge 512;

Focal Loss + balanced sampler;

Final_oof_macro_f1 ≈ 0.7934 ;

Решение подходит как помощник модерации и основа для product integration.

Ключевой тезис для заказчика

**Мы собрали не только модель, а воспроизводимый путь до внедрения:
данные → обучение → оценка → артефакты → demo/API.**

Спасибо! Готовы к вопросам.